

OS 6 MODELOS DE IA E SEUS CUSTOS REAIS

Para quem precisa escolher entre qualidade, velocidade e orçamento na hora de rodar IA em produção.



OS MODELOS EM PRODUÇÃO HOJE

Existem seis modelos que dominam o mercado de IA prática agora. Cada um foi desenhado para um tipo de tarefa diferente, e o preço varia bastante. A escolha não é sobre qual é melhor no absoluto, mas qual resolve seu problema com o custo que você aguenta.

Os modelos mais conhecidos competem por três coisas: velocidade de resposta, qualidade da resposta e custo por requisição. Um modelo rápido e barato pode ser menos preciso. Um modelo muito preciso pode ser lento e caro. Você está sempre negociando entre esses três.

CUSTO POR 1 MILHÃO DE REQUISIÇÕES

Quando você roda IA em escala, o preço não é em reais por pergunta. É em quanto custa fazer um milhão de perguntas. Sonnet 5.5 entrou no mercado custando 30% menos que sua versão anterior para fazer a mesma coisa, ou 30% mais rápido pagando o mesmo.

Comparar custo entre modelos é comparar quanto a app gasta para cada função que executa. Uma empresa que processa dez milhões de documentos por mês sente cada centavo dessa diferença. Uma startup que roda mil requisições por dia quase não sente. Mas a conta sempre importa.

TAREFAS RÁPIDAS VS ANÁLISE PESADA

Nem toda tarefa de IA precisa do modelo mais poderoso. Uma busca por palavra-chave em um chat, um sumário rápido, uma resposta simples pede menos potência. Modelos mais leves e baratos sobram para essas coisas. Você poupa rodando o modelo certo para o trabalho certo.

Análise pesada é diferente. Quando você precisa pensar em tudo que tem em um documento de cem páginas, ou conectar pontos em dados complexos, um modelo mais lento mas mais preciso vale a pena, mesmo que custe mais. O trabalho demanda qualidade, e qualidade tem custo.

O TRADE-OFF QUE NINGUÉM ESCAPA

Velocidade, qualidade e preço: escolhe dois. Quem promete os três está mentindo. Claude Sonnet 5.5 melhorou velocidade e abaixou preço, mas em tarefas muito complexas continua perdendo para modelos maiores em precisão.

O que mudou é que agora dá para rodar mais IA por menos dinheiro sem abrir mão de qualidade para a maioria das coisas. Isso expande quem pode permitir IA em produção. Pequenas empresas, startups, apps que pareciam inviáveis agora entram do jogo porque a conta fecha.

POR QUE ISSO MUDA O MERCADO

Até pouco tempo, IA era experimento caríssimo. Agora é produção em larga escala. Quando custo cai e velocidade sobe, novos problemas viram solucionáveis. Uma app que era cara demais para escalar fica viável. Um serviço que era lento demais para usar em tempo real passa a funcionar.

Você não escolhe qual IA sua app usa. Mas apps que ficaram baratas e rápidas tendem a ser melhores de usar. Chatbots que não travavam antes agora respondem na hora. Análise de imagem em fotos que você tira fica possível sem internet. Isso é o que importa na ponta do consumidor.

A guerra agora é por custo e velocidade, não por features. Acompanhe @prime8.ia para entender como essas disputas impactam os serviços que você usa todo dia.